

Implementación de clasificador naïve Bayes como predictor del nivel de impacto de noticias financieras



Tecnológico
de Monterrey

Jessica Milagros Cordero Rivera¹ Diego Rodrigo González Ramírez¹

Jose Ángel Lechuga Carrasco¹ Julio Lizárraga Beltrán¹

¹Escuela de Ingeniería y Ciencias

Matrículas: A01647083 —A01647198 —A00228198 —A01743628

Palabras Clave: noticias financieras, procesamiento de lenguaje natural, Naïve Bayes, clasificación de texto, impacto de mercado

13 de septiembre de 2026

Resumen

La clasificación automática de noticias financieras resulta crucial para anticipar movimientos en el mercado. Este estudio evalúa la efectividad de un clasificador Naïve Bayes Multinomial para determinar la relevancia financiera de un corpus de noticias a partir de su contenido textual. La base de datos se dividió en conjuntos de entrenamiento y prueba para validar el ajuste del algoritmo. Los resultados revelaron variaciones en el rendimiento según la distribución de los datos, alcanzando una exactitud predictiva de 0.579. Estos hallazgos sugieren que, aunque el clasificador identifica patrones básicos, la complejidad del vocabulario financiero requiere complementar el análisis con técnicas avanzadas de selección de características.

1. Introducción

Los mercados financieros operan alrededor de una gran cantidad continua de información, modificando las expectativas de inversionistas y, por lo tanto, relacionarse con cambios en precios, volumen de negociación y toma de decisiones en general. Dentro de este flujo de información, las noticias financieras constituyen una fuente particularmente relevante, la evidencia empírica ha mostrado que el contenido lingüístico de las noticias contiene información económicamente significativa. Se ha encontrado que un mayor pesimismo en los medios se asocia con presión a la baja sobre los precios del mercado y con variaciones en el volumen de negociación [1]. Adicional a lo anterior, se ha observado que la presencia de lenguaje negativo en noticias podía aportar información sobre sus resultados contables y rendimientos bursátiles posteriores [2]. Además, se ha documentado que la información contenida en las noticias puede conservar capacidad predictiva sobre los rendimientos del mercado [3].

Sin embargo, el análisis de noticias financieras conlleva varias complicaciones. A diferencia de variables numéricas, como precios o rendimientos, los titulares corresponden a una cadena de palabras que pueden contener ambigüedad y/o dependencia del contexto. Es bien sabido en la literatura previa que la orientación semántica general de una frase puede ser distinta

de la polaridad previa de las palabras individuales. [4]. Por ello, identificar si una noticia puede generar un impacto relevante en el mercado constituye un problema más complejo que identificar únicamente si su lenguaje es positivo, negativo o neutral.

El clasificador Naïve Bayes es un algoritmo de aprendizaje automático supervisado que se utiliza para tareas de clasificación, como la clasificación de texto. Su funcionamiento parte de la estimación de la probabilidad de pertenencia a una clase a partir de las características observadas y de una hipótesis simplificadora de independencia condicional entre los predictores [5]. En aplicaciones de cadenas de texto, las palabras pueden representarse mediante su frecuencia dentro de cada observación. Se ha mostrado que el modelo multinomial de Naïve Bayes presenta un comportamiento efectivo para tareas de clasificación de texto basadas en frecuencias de palabras [6]. Su simplicidad computacional, capacidad para trabajar con matrices dispersas y fácil interpretación hacen de este algoritmo uno apropiado para estudiar titulares financieros. Además, ya se han aplicado modelos Naïve Bayes sobre información de noticias financieras y se encontró que ésta permitía predecir con mayor precisión la dirección de cambios en la volatilidad que la dirección del precio de cierre [7]. Esto muestra la utilidad de este clasificador en el contexto de noticias financieras.

Este trabajo busca determinar si la información contenida en los titulares de noticias financieras, junto con las variables contextuales disponibles, permiten discriminar entre noticias de *Impacto Alto* y noticias de *Impacto Medio/Bajo*. Se propone como hipótesis que la distribución de determinadas palabras en los titulares, junto con las características financieras disponibles contiene información suficiente para identificar noticias pertenecientes a la categoría de impacto, ya sea alto o medio/bajo.

El objetivo de este estudio es desarrollar y evaluar un clasificador Naïve Bayes capaz de estimar la categoría de impacto de una noticia financiera a partir de la información contenida en su titular y de variables seleccionadas. Para ello, los titulares se procesan mediante técnicas de Procesamiento del Lenguaje Natural (NLP) que incluyen tokenización, eliminación de palabras de uso común y construcción de una matriz dispersa de frecuencias de términos [8]. Sobre esta representación se entrena un modelo de clasificación y se mide su desempeño mediante *accuracy*, precisión, *recall*, F1-score y matriz de confusión.

2. Metodología

2.1. Enfoque y tipo de estudio

Se empleó un enfoque cuantitativo, no experimental y predictivo, basado en técnicas de procesamiento de lenguaje natural y aprendizaje supervisado para clasificar el nivel de impacto de noticias financieras.

2.2. Fuente de datos

Los datos fueron proporcionados por una base de datos que contiene información sobre titulares de noticias financieras entre febrero y agosto de 2025. La base de datos fue proporcionada por nuestro profesor de el Instituto Tecnológico de Estudios Superiores Monterrey

2.3. Herramientas

La realización y evaluación del modelo se realizaron utilizando entorno de desarrollo integrado RStudio (v2026.08.2), utilizando el lenguaje de programación estadístico R (v4.5.3) [9] mediante el sistema de código abierto Quarto (v1.8.25), utilizando los paquetes `naivebayes` (v1.0.0), `tidyverse` (v2.0.0), `tidytext` (v0.4.3), `stringr` (v1.6.0), `ggplot2` (v4.0.3) y `dplyr` (v1.2.1).

2.4. Preprocesamiento

Se exploró la distribución de nuestra variable objetivo (el nivel de impacto) para poder facilitarnos el modelado inicial o para evitar desbalances severos. Simplificamos el problema recodificando la variable objetivo a dos categóricas (impacto alto e impacto medio/bajo). Se utilizó la función `unnest_tokens()` para descomponer los titulares de noticias en palabras individuales y se removieron las palabras comunes en inglés utilizando el dataset `stop_words`.

2.5. Construcción del modelo

Construimos la matriz de frecuencias de palabras donde cada renglón represente un titular y las columnas correspondan al vocabulario retenido. Dividimos la matriz de datos en training y test set, después se entrenó un clasificador Naïve Bayes empleando variables Bernoulli para representar la presencia o ausencia de términos, distribuciones categóricas para sentimiento y sector, y distribuciones gaussianas para las variables continuas. El modelo Naïve Bayes fue ajustado empleando suavizado de Laplace con un parámetro igual a 1.

2.6. Implementación de las métricas de desempeño

Hicimos pruebas utilizando el conjunto de prueba, calculamos el accuracy, precision, recall, F1-score y matriz de confusión para poder identificar los patrones de acierto y error del modelo. El conjunto final fue dividido de manera estratificada utilizando 70 % de las observaciones para entrenamiento y 30 % para prueba, fijando una semilla para garantizar la reproducibilidad. La evaluación se realizó sobre 864 observaciones del conjunto de prueba, considerando como clase positiva a *Impacto Alto*.

3. Aplicación

3.1. Resultados

Después del preprocesamiento de los titulares se obtuvo una matriz dispersa formada por 2,876 noticias y un vocabulario de 238 términos, con un total de 18,248 apariciones de palabras. El conjunto de entrenamiento conservó una distribución de 31.91 % de noticias clasificadas como *Impacto Alto* y 68.09 % como *Impacto Medio/Bajo*. Esta distribución fue prácticamente equivalente en el conjunto de prueba, donde la prevalencia de noticias de alto impacto fue de 31.94 %. La matriz de confusión obtenida se presenta en la Tabla 1.

Cuadro 1

Matriz de confusión del clasificador Naïve Bayes en el conjunto de prueba.

Predicción	Clase real	
	Impacto Alto	Impacto Medio/Bajo
Impacto Alto	102	190
Impacto Medio/Bajo	174	398

De las 276 noticias realmente pertenecientes a la categoría de *Impacto Alto*, el modelo identificó correctamente 102, mientras que 174 fueron clasificadas erróneamente como *Impacto Medio/Bajo*. Por otro lado, de las 588 noticias pertenecientes a la categoría *Impacto Medio/Bajo*, 398 fueron correctamente identificadas y 190 fueron clasificadas como de alto impacto.

Las principales métricas de desempeño se presentan en la Tabla 2. El modelo obtuvo una *accuracy* de 0.5787, equivalente a 57.87 %. La precisión para la clase *Impacto Alto* fue de 0.3493, lo que significa que aproximadamente 35 de cada 100 noticias clasificadas por el modelo como de alto impacto pertenecían realmente a dicha categoría. El *recall* fue de 0.3696. Finalmente, el F1-score alcanzó un valor de 0.359.

Cuadro 2

Métricas de desempeño del modelo sobre el conjunto de prueba.

Métrica	Valor
Accuracy	0.5787
Precision	0.3493
Recall / Sensibilidad	0.3696
F1-score	0.3590
Especificidad	0.6769
Balanced Accuracy	0.5232
Kappa	0.0457

3.2. Discusión

Los resultados obtenidos muestran que el clasificador Naïve Bayes fue capaz de construir una regla probabilística de clasificación a partir de la información lingüística de los titulares y de las

variables financieras seleccionadas; sin embargo, su capacidad para distinguir adecuadamente entre noticias de *Impacto Alto* y *Impacto Medio/Bajo* fue limitada. La categoría mayoritaria representa 68.06 % del conjunto de prueba, por lo que una estrategia que clasificara todas las noticias como *Impacto Medio/Bajo* obtendría una exactitud superior a la del modelo propuesto.

Este resultado sugiere que la hipótesis planteada sólo recibe apoyo limitado bajo la especificación actual del modelo. Los titulares y las variables contienen cierta información que permite diferenciar las clases, como sugiere una *balanced accuracy* ligeramente superior a 0.5; sin embargo, la señal extraída no fue suficiente para producir un clasificador con desempeño superior a la base de la clase mayoritaria. Esto no implica necesariamente que los titulares carezcan de información relacionada con el comportamiento financiero. Estudios previos han demostrado que el contenido lingüístico de las noticias se relaciona con variables del mercado, incluyendo rendimientos, volumen de negociación y comportamiento posterior de los activos [1-3]. Más bien, los resultados sugieren que transformar esta información en una clasificación binaria de nivel de impacto constituye una tarea distinta y posiblemente más compleja.

En este sentido, los resultados son consistentes con una de las principales dificultades señaladas en la literatura sobre procesamiento de lenguaje financiero, donde se argumenta que la orientación semántica de una expresión financiera no necesariamente puede obtenerse a partir de la interpretación aislada de sus palabras.[4] El enfoque utilizado en este estudio representa cada titular mediante la presencia individual de términos y, por diseño, no conserva el orden de las palabras ni las relaciones existentes entre ellas.

El desempeño tampoco invalida la utilidad general de Naïve Bayes para clasificación de texto, ya que se ha encontrado que este tipo de modelos puede presentar resultados competitivos en problemas caracterizados por vocabularios amplios y representaciones dispersas [6]. No obstante, existen diferencias importantes con el presente trabajo. En particular, aunque inicialmente se construyó una matriz de frecuencias, las características textuales fueron posteriormente binarizadas, de modo que el modelo implementado utiliza la presencia o ausencia de cada término y no su frecuencia absoluta. Esto aproxima el tratamiento del texto a un modelo Bernoulli..

Esta distinción entre objetivos es relevante porque, dentro de los antecedentes considerados en este trabajo, la mayoría de los estudios relacionan el lenguaje financiero con sentimiento, rendimientos, precio o volatilidad, mientras que la clasificación directa de titulares en categorías de *Impacto Alto* e *Impacto Medio/Bajo* representa una formulación menos habitual. No se pretende establecer con ello que ésta sea la primera aplicación de este tipo, ya que la revisión realizada no fue una revisión sistemática de toda la literatura disponible; sin embargo, sí constituye una diferencia respecto de los principales antecedentes utilizados como referencia en este estudio.

Desde una perspectiva financiera, la matriz de confusión permite además distinguir dos tipos de error con implicaciones diferentes. Los 190 falsos positivos corresponden a noticias clasificadas como de alto impacto que en realidad pertenecían a la categoría medio/bajo. Si el clasificador

fuera utilizado como herramienta de apoyo para una persona inversionista, estos errores podrían producir una reacción excesiva ante información poco relevante, generar operaciones innecesarias, incrementar costos de transacción o provocar modificaciones injustificadas del portafolio. Una cantidad elevada de falsos positivos también podría disminuir la confianza en un sistema automático de alertas.

Por otro lado, los 174 falsos negativos representan noticias realmente de alto impacto que el modelo no logró identificar. En aplicaciones orientadas a vigilancia de riesgo, este error podría ser incluso más relevante, ya que implicaría omitir acontecimientos potencialmente importantes y reducir la oportunidad de ajustar posiciones, realizar coberturas o reaccionar ante cambios relevantes del mercado. Desde esta perspectiva, el reducido *recall* de 36.96 % constituye una de las principales limitaciones prácticas del modelo. Si el objetivo prioritario fuera funcionar como sistema de alerta temprana, sería razonable favorecer una mayor sensibilidad aun a costa de aceptar un incremento moderado en falsos positivos.

4. Conclusiones

El clasificador Naïve Bayes multinomial entrenado con obtuvo un desempeño algo débil con una accuracy de 57.87 %, que quedó por debajo de la tasa de no información de 68.06 %, o sea que, la que se obtiene con solo predecir siempre la clase mayoritaria. El Kappa de 0.0457 nos reafirma que el modelo no concuerda mucho con la realidad o sea que es casi igual a hacerlo al azar, y la exactitud balanceada de 52.32 % refuerza esta conclusión.

Para la clase de interés (Impacto Alto) el modelo mostro una sensibilidad de 36.96 %, con una precisión de 34.9 % y un F1 de 35.9 %. De 292 titulares clasificados como Impacto Alto, solo 102 lo eran en realidad y se dejaron pasar 174 casos reales de Impacto Alto.

Esto muestra que la idea de tratar cada palabra como si no tuviera relación con las demás, junto con solo fijarse en si una palabra aparece o no (sin importar cuántas veces se repite), no le da al modelo suficiente información para distinguir entre las dos categorías de impacto. En resumen el Naïve Bayes no logro hacerlo mejor que si simplemente se eligiera siempre la categoría mas común, así que la forma en que se representaron las palabras no fue suficiente para esta ocasión.

5. Referencias

1. Tetlock, P. C. Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *The Journal of Finance* **62**, 1139-1168 (2007).
2. Tetlock, P. C., Saar-Tsechansky, M. y Macskassy, S. More Than Words: Quantifying Language to Measure Firms' Fundamentals. *The Journal of Finance* **63**, 1437-1467 (2008).
3. Heston, S. L. y Sinha, N. R. News vs. Sentiment: Predicting Stock Returns from News Stories. *Financial Analysts Journal* **73**, 67-83 (2017).

4. Malo, P., Sinha, A., Korhonen, P., Wallenius, J. y Takala, P. Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *Journal of the Association for Information Science and Technology* **65**, 782-796 (2014).
5. Kavlakoglu, E. ¿Qué son los clasificadores Naïve Bayes? IBM. <https://www.ibm.com/mx-es/think/topics/naive-bayes> (2026).
6. McCallum, A. y Nigam, K. A Comparison of Event Models for Naive Bayes Text Classification. En *Proceedings of the AAAI-98 Workshop on Learning for Text Categorization* 41-48 (AAAI Press, 1998).
7. Atkins, A., Niranjan, M. y Gerding, E. Financial News Predicts Stock Market Volatility Better Than Close Price. *The Journal of Finance and Data Science* **4**, 120-137 (2018).
8. CN, P. *Confusion matrix in R: A complete guide* ago. de 2022.
9. R Core Team. *R: A Language and Environment for Statistical Computing* R Foundation for Statistical Computing (Vienna, Austria, 2021).