

Implementación de clasificador naïve Bayes como predictor del nivel de impacto de noticias financieras



Tecnológico
de Monterrey

Jessica Milagros Cordero Rivera¹ Diego Rodrigo González Ramírez¹

Jose Ángel Lechuga Carrasco¹ Julio Lizárraga Beltrán¹

¹Escuela de Ingeniería y Ciencias

Matrículas: A01647083 —A01647198 —A00228198 —A01743628

Palabras Clave:

13 de septiembre de 2026

Resumen

a

1. Introducción

Los mercados financieros operan alrededor de una gran cantidad continua de información, modificando las expectativas de inversionistas y, por lo tanto, relacionarse con cambios en precios, volumen de negociación y toma de decisiones en general. Dentro de este flujo de información, las noticias financieras constituyen una fuente particularmente relevante, la evidencia empírica ha mostrado que el contenido lingüístico de las noticias contiene información económicamente significativa. Se ha encontrado que un mayor pesimismo en los medios se asocia con presión a la baja sobre los precios del mercado y con variaciones en el volumen de negociación [1]. Adicional a lo anterior, se ha observado que la presencia de lenguaje negativo en noticias podía aportar información sobre sus resultados contables y rendimientos bursátiles posteriores [2]. Además, se ha documentado que la información contenida en las noticias puede conservar capacidad predictiva sobre los rendimientos del mercado [3].

Sin embargo, el análisis de noticias financieras convella varias complicaciones. A diferencia de variables numéricas, como precios o rendimientos, los titulares corresponden a una cadena de palabras que pueden contener ambigüedad y/o dependencia del contexto. Es bien sabido en la literatura previa que la orientación semántica general de una frase puede ser distinta de la polaridad previa de las palabras individuales. [4]. Por ello, identificar si una noticia puede generar un impacto relevante en el mercado constituye un problema más complejo que identificar únicamente si su lenguaje es positivo, negativo o neutral.

El clasificador Naïve Bayes es un algoritmo de aprendizaje automático supervisado que se utiliza para tareas de clasificación, como la clasificación de texto. Su funcionamiento parte de la estimación de la probabilidad de pertenencia a una clase a partir de las características observadas y de una hipótesis simplificadora de independencia condicional entre los predictores

[5]. En aplicaciones de cadenas de texto, las palabras pueden representarse mediante su frecuencia dentro de cada observación. Se ha mostrado que el modelo multinomial de Naïve Bayes presenta un comportamiento efectivo para tareas de clasificación de texto basadas en frecuencias de palabras [6]. Su simplicidad computacional, capacidad para trabajar con matrices dispersas y fácil interpretación hacen de este algoritmo uno apropiado para estudiar titulares financieros. Además, ya se han aplicado modelos Naïve Bayes sobre información de noticias financieras y se encontró que ésta permitía predecir con mayor precisión la dirección de cambios en la volatilidad que la dirección del precio de cierre [7]. Esto muestra la utilidad de este clasificador en el contexto de noticias financieras.

Este trabajo busca determinar si la información contenida en los titulares de noticias financieras, junto con las variables contextuales disponibles, permiten discriminar entre noticias de *Impacto Alto* y noticias de *Impacto Medio/Bajo*. Se propone como hipótesis que la distribución de determinadas palabras en los titulares, junto con las características financieras disponibles contiene información suficiente para identificar noticias pertenecientes a la categoría de impacto, ya sea alto o medio/bajo.

El objetivo de este estudio es desarrollar y evaluar un clasificador Naïve Bayes capaz de estimar la categoría de impacto de una noticia financiera a partir de la información contenida en su titular y de variables seleccionadas. Para ello, los titulares se procesan mediante técnicas de Procesamiento del Lenguaje Natural (NLP) que incluyen tokenización, eliminación de palabras de uso común y construcción de una matriz dispersa de frecuencias de términos. Sobre esta representación se entrena un modelo de clasificación y se mide su desempeño mediante *accuracy*, precisión, *recall*, F1-score y matriz de confusión.

2. Metodología

2.1. Enfoque y tipo de estudio

Se empleó un enfoque cuantitativo, correlacional, no experimental, basado en el uso de GBN para encontrar las relaciones de dependencia probabilística entre los biomarcadores.

2.2. Fuente de datos

2.3. Herramientas

La realización y evaluación del modelo se realizaron utilizando entorno de desarrollo integrado RStudio (v2026.08.2), utilizando el lenguaje de programación estadístico R (v4.5.3) [8] mediante el sistema de código abierto Quarto (v1.8.25), utilizando los paquetes *bnlearn* (v5.2.1)[9], *tidyverse* (v2.0.0), *tidytext* (v0.4.3), *stringr* (v1.6.0), *ggplot2* (v4.0.3) y *dplyr* (v1.2.1).

2.4. Preprocesamiento

2.5. Construcción y selección del modelo global

2.6. Estrategia analítica para consultas probabilísticas

3. Aplicación

3.1. Resultados

3.2. Discusiones

4. Conclusiones

5. Referencias

1. Tetlock, P. C. Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *The Journal of Finance* **62**, 1139-1168 (2007).
2. Tetlock, P. C., Saar-Tsechansky, M. y Macskassy, S. More Than Words: Quantifying Language to Measure Firms' Fundamentals. *The Journal of Finance* **63**, 1437-1467 (2008).
3. Heston, S. L. y Sinha, N. R. News vs. Sentiment: Predicting Stock Returns from News Stories. *Financial Analysts Journal* **73**, 67-83 (2017).
4. Malo, P., Sinha, A., Korhonen, P., Wallenius, J. y Takala, P. Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts. *Journal of the Association for Information Science and Technology* **65**, 782-796 (2014).
5. Kavlakoglu, E. ¿Qué son los clasificadores Naïve Bayes? IBM. <https://www.ibm.com/mx-es/think/topics/naive-bayes> (2026).
6. McCallum, A. y Nigam, K. A Comparison of Event Models for Naive Bayes Text Classification. En *Proceedings of the AAAI-98 Workshop on Learning for Text Categorization* 41-48 (AAAI Press, 1998).
7. Atkins, A., Niranjan, M. y Gerding, E. Financial News Predicts Stock Market Volatility Better Than Close Price. *The Journal of Finance and Data Science* **4**, 120-137 (2018).
8. R Core Team. *R: A Language and Environment for Statistical Computing* R Foundation for Statistical Computing (Vienna, Austria, 2021).
9. Scutari, M. y Denis, J.-B. *Bayesian Networks with Examples in R* 2nd. ISBN 978-0367366513 (Chapman y Hall, Boca Raton, 2021).